

## Trabalho no 4 v2 – Palavras mais procuradas

### Algoritmos e Estruturas de Dados

### 2019/2020 – 2º Semestre

Upload: (link a disponibilizar no infoestudante)

Data Limite: até 15mn depois do fim da respetiva 4ª aula pratica

**O RELATÓRIO E LISTAGEM DO CÓDIGO DESENVOLVIDO DEVEM SER SUBMETIDOS NUM ÚNICO DOCUMENTO PDF**

Nome: Rodrigo Fernando Henriques Sobral nº: 2018298209 PL: 2

Nº de horas de trabalho: Aulas Práticas de Laboratório: 8H Fora de Sala de Aula: 5H

CLASSIFICAÇÃO:

(A Preencher pelo Docente)

#### Análise Empírica de Complexidade

- Faça o download dos 4 textos. Preencha a Tabela 1 com os valores para cada texto. Use o tempo médio de 20 execuções. Considere essa caracterização na análise qualitativa mais adiante.
- Preencha a Tabela 2 com informação sobre as estruturas de dados e algoritmos que escolheu.
- Preencha a Tabela 3 com os tempos de ordenamento para cada algoritmo.

#	Operação	Texto A	Texto B	Texto C	Texto D
1	Carregamento (tempo em: s )	0 .07	130 .3	165 .1	153 .05
2	Núm. palavras distintas	75	1 354	1 354	1 354
3	Núm. utilizadores distintos	2	632	632	632
4	Núm. Pares (palavra,utilizador) distintos	150	4 159	4 159	4 159
5	Núm. Total de palavras	156	140 000	140 000	140 000
6	Núm. Total de utilizadores	156	140 000	140 000	140 000
7	Faz algum ordenamento? Caracterize.	Alfabeticamente crescente e aumento progressivo do número de caracteres.	Não.	Repetição massiva e consecutiva e alfabeticamente crescente.	Curta repetição consecutiva e alfabeticamente crescente.

#	Tarefa	Estrutura de dados	Algoritmo de ordenamento
---	--------	--------------------	--------------------------

8	A1	Arrays	Merge Sort
9	A2	Arrays	Radix Sort + Counting Sort

#	Tempos de Ordenamento em [ $\mu$ s ]	A1 PESQ_GLOBAL	A1 PESQ_UTILIZADORES	A2 PESQ_GLOBAL	A2 PESQ_UTILIZADORES
10	Texto A	347 .05	99 .8	299 .4	249 .1
11	Texto B	7 608 .6	6 541 .0	45 599 .85	28 327 .85
12	Texto C	10 419 .6	8 538 .4	53 265 .4	30 862 .25
13	Texto D	7 843 .85	6 254 .05	51 695 .5	30 853 .65

### Reflexão sucinta sobre os resultados obtidos

(Formato de referência: Arial 10pt; texto para além do número de linhas não é considerado e desvaloriza o relatório)

1. Comente como as estruturas de armazenamento definidas na Tabela 2 influenciaram os tempos de armazenamento e processamento.

Se utilizássemos outra estrutura de dados, os tempos de armazenamento não seriam melhores (devido a rotações ou acessos mais demorados a memória). Porém, no requisito "processamento", uma árvore binária ficaria em vantagem já que os dados estariam *a priori* quase, ou, completamente ordenados.

2. Analise os resultados dos algoritmos para as tarefas A1 e A2. Os resultados foram os esperados? O input mostrou-se relevante? Justifique.  
(8 linhas)

O algoritmo A1 (Merge Sort) possui complexidade  $O(n \cdot \log(n))$ , e os dois algoritmos A2, Radix e Counting Sort, complexidades temporais de  $O((n+b) \cdot \log_b(k))$  e  $O(n+k)$ , respetivamente. Esta informação vai ao encontro dos dados levantados, já que a comparação de bases mostrou uma maior eficácia em quantidades massivas de informação, como é o caso. Portanto sim, os resultados estão dentro dos esperados. O input também é relevante. No caso A1, quanto maior for o input, mais bifurcações e unificações serão necessárias, o que causa um aumento temporal significativo. No caso A2, quanto mais dígitos o input tiver, mais ciclos e comparações precisam de ser feitas (Radix), e quanto maior o próprio input, mais demorado será o preenchimento da estrutura auxiliar (Counting).

3. Compare as duas formas de ordenamento: por registo vs. por endereço. Quando será apropriada a escolha de cada uma? (6 linhas)

Na utilização dum ordenamento por endereço, não há efetivamente a troca de elementos, apenas a alteração de endereços para os quais os ponteiros apontam. Por outro lado, no ordenamento por registo há um movimento de elementos na memória, o que consequentemente exige um maior tempo de processamento. Posto isto, concluímos que em quantidades massivas de informação, como é o caso, ficaria mais em conta a utilização dum ordenamento por endereço.

## Algoritmo A1

```

1  from datetime import datetime    You, a day ago + 3 question lefting
2
3  def receiveCommands():
4      # [ word , [all_searchers] , [distinct_searchers] ]
5      database=[]
6      results=""
7      while True:
8          command=input().strip("\n")
9
10         if command=="PALAVRAS":
11             startTime= datetime.now()
12             totWords=0
13             aux=input().strip("\n")
14             while (aux!="FIM."):
15                 totWords+=1
16                 aux=aux.split(" ")
17                 index= isIn(database, aux[0])
18                 if index== -1: database.append([aux[0], [aux[1]], [aux[1]]])
19                 elif aux[1] not in database[index][1]:
20                     database[index][1].append(aux[1])
21                     database[index][2].append(aux[1])
22                 else: database[index][1].append(aux[1])
23                 aux=input().strip("\n")
24             loadingTextTime= (datetime.now()-startTime).seconds
25             results+= "GUARDADAS\n"
26         elif command=="PESQ_GLOBAL":
27             startTime= datetime.now()
28             mergeSort(database, 1)
29             sortGlobalTime= (datetime.now()-startTime).microseconds
30             i=1
31             results+=str(database[0][0])
32             while i<len(database) and len(database[0][1])==len(database[i][1]):
33                 results+=" "+str(database[i][0])
34                 i+=1
35             results+="\n"
36         elif command=="PESQ_UTILIZADORES":
37             startTime= datetime.now()
38             mergeSort(database, 2)
39             sortUtilizadoresTime= (datetime.now()-startTime).microseconds
40             i=1
41             results+=str(database[0][0])
42             while i<len(database) and len(database[0][2])==len(database[i][2]):
43                 results+=" "+str(database[i][0])
44                 i+=1
45             results+="\n"
46         elif command=="TCHAU": break
47         else: print("Incorrect command.")
48
49     #print(results, end="")
50     return [database, loadingTextTime, sortGlobalTime, sortUtilizadoresTime, totWords]
51
52 def isIn(database, word):
53     for search in database:
54         if word.upper()==search[0].upper(): return database.index(search)
55     return -1
56
57 def mergeSort(database, command):
58     if len(database)>1:
59         mid = len(database)//2
60         left_array, right_array = database[:mid], database[mid:]

```

```

61
62         mergeSort(left_array, command)
63         mergeSort(right_array, command)
64
65         database.clear()
66         while len(left_array) > 0 and len(right_array) > 0:
67             if len(left_array[0][command]) >= len(right_array[0][command]):
68                 database.append(left_array[0])
69                 left_array.pop(0)
70             else:
71                 database.append(right_array[0])
72                 right_array.pop(0)
73
74         for i in left_array:
75             database.append(i)
76         for i in right_array:
77             database.append(i)
78
79     #=====
80
81 def getDistinctUsers(database):
82     tot_users=[]
83     for search in database:
84         for user in search[2]:
85             if user not in tot_users: tot_users.append(user)
86     return len(tot_users)
87 def getWordUserPair(database):
88     counter=0
89     for search in database: counter+=len(search[2])
90     return counter
91
92 if __name__ == "__main__":
93     [database, loadingTextTime, sortGlobalTime, sortUtilizadoresTime, totWords]= receiveCommands()
94     for i in range(19):
95         results=receiveCommands()
96         loadingTextTime+= results[1]
97         sortGlobalTime+= results[2]
98         sortUtilizadoresTime+= results[3]
99         print("=====")
100        print("DATA:")
101        print("Loading Text Time:", loadingTextTime/20)
102        print("Distinct Words:", len(database))
103        print("Distinct Users:", getDistinctUsers(database))
104        print("Distinct Word-User Pair:", getWordUserPair(database))
105        print("Total Words:", totWords)
106        print("Total Users:", totWords)
107
108    print("Sorting Global Time:", sortGlobalTime/20)
109    print("Sorting Utilizadores Time:", sortUtilizadoresTime/20)

```

## Algoritmo A2

```

1  from datetime import datetime    You, a day ago + 3 question lefting
2
3  def receiveCommands():
4      database=[] # [ word , [all_searchers] , [distinct_searchers] ]
5      results=""
6      while True:
7          command=input().strip("\n")
8
9          if command=="PALAVRAS":
10             startTime= datetime.now()
11             totWords=0
12             aux=input().strip("\n")
13             while (aux!="FIM."):
14                 totWords+=1
15                 aux=aux.split(" ")
16                 index= isin(database, aux[0])
17                 if index== -1: database.append([aux[0], [aux[1]], [aux[1]]])
18                 elif aux[1] not in database[index][1]:
19                     database[index][1].append(aux[1])
20                     database[index][2].append(aux[1])
21                 else: database[index][1].append(aux[1])
22                 aux=input().strip("\n")
23             loadingTextTime= (datetime.now()-startTime).seconds
24             results+= "GUARDADAS\n"
25             elif command=="PESQ_GLOBAL":
26                 startTime= datetime.now()
27                 database= radixSorting(database, 1)
28                 sortGlobalTime= (datetime.now()-startTime).microseconds
29                 results+=str(database[0][0])
30                 i=1
31                 while i<len(database) and len(database[0][1])==len(database[i][1]):
32                     results+=" "+str(database[i][0])
33                     i+=1
34                 results+="\n"
35             elif command=="PESQ_UTILIZADORES":
36                 startTime= datetime.now()
37                 database= radixSorting(database, 2)
38                 sortUtilizadoresTime= (datetime.now()-startTime).microseconds
39                 results+=str(database[0][0])
40                 i=1
41                 while i<len(database) and len(database[0][2])==len(database[i][2]):
42                     results+=" "+str(database[i][0])
43                     i+=1
44                 results+="\n"
45             elif command=="TCHAU": break
46             else: print("Incorrect command.")
47
48             #print(results, end='')
49             return [database, loadingTextTime, sortGlobalTime, sortUtilizadoresTime, totWords]
50
51 def isin(database, word):
52     for search in database:
53         if word.upper()==search[0].upper(): return database.index(search)
54     return -1
55
56 def radixSorting(database, command):
57     searchesArray= [str(len(search[command])) for search in database]
58     longestDigits= len(str(max(searchesArray, key=len)))
59     for num_digits in range(longestDigits):
60         digitsArray=[]
61         for digits in searchesArray:
62             if len(digits)-1-num_digits<0: digitsArray.append(-1)
63             else: digitsArray.append(int(digits[len(digits)-1-num_digits]))
64         database= countingSort(database, digitsArray)
65         searchesArray=[str(len(search[command])) for search in database]
66         return database
67
68 def countingSort(database, digitsArray):
69     smaller=min(digitsArray)
70     indexArray= [0 for i in range(max(digitsArray)-smaller+1)]
71     sortedArray=[]
72     for number in digitsArray: indexArray[number-smaller]+=1
73     del smaller, number
74     for occurrences in range(len(indexArray)-1, -1, -1):
75         while indexArray[occurrences]!=0:    You, a day ago + 3 question
76             greater=digitsArray.index(max(digitsArray))
77             indexArray[occurrences]-=1
78             sortedArray.append(database[greater])
79             digitsArray.pop(greater)
80             database.pop(greater)
81         return sortedArray
82
83 def getDistinctUsers(database):
84     tot_users=[]
85     for search in database:
86         for user in search[2]:
87             if user not in tot_users: tot_users.append(user)
88     return len(tot_users)
89
90 def getWordUserPair(database):
91     counter=0
92     for search in database: counter+=len(search[2])
93     return counter
94
95 if __name__ == "__main__":
96     [database, loadingTextTime, sortGlobalTime, sortUtilizadoresTime, totWords]= receiveCommands()
97     for i in range(19):
98         results=receiveCommands()
99         loadingTextTime+= results[1]
100         sortGlobalTime+= results[2]
101         sortUtilizadoresTime+= results[3]
102         print("=====")
103         print("DATA:")
104         print("Loading Text Time:", loadingTextTime/20)
105         print("Distinct Words:", len(database))
106         print("Distinct Users:", getDistinctUsers(database))
107         print("Distinct Word-User Pair:", getWordUserPair(database))
108         print("Total Words:", totWords)
109         print("Total Users:")
110
111         print("Sorting Global Time:", sortGlobalTime/20)
112         print("Sorting Utilizadores Time:", sortUtilizadoresTime/20)

```

Bom trabalho, os Docentes da Disciplina,  
Carlos L Bento e Catarina Silva